

基于图卷积神经网络的商品共购网络分析

《金融科技导论与实践》智能营销大作业报告

混合 2209 马宇恒 3220105015
混合 2209 肖一鸣 3220105015

2024 年 7 月 15 日

目录

1	研究背景与意义	2
2	国内外研究现状	2
2.1	CGN 之前的工作	2
2.2	CGN 模型提出	3
2.3	局限与发展	3
3	研究思路	4
4	论文引用网络分析	5
5	亚马逊共购网络分析	5

1 研究背景与意义

图卷积神经网络（GCN）是一种重要而基础的图学习方式，在图的分类工作中表现出色 [4]，其优势如下：

1. 可以处理各种不规则的无向图数据，如社交网络、推荐系统、生物信息学等，适应范围广。
2. 只依赖较小规模的标签数据，就可以对整个图进行分类预测。
3. 可以将节点的高维附加信息（Side Information）作为嵌入特征（Embedding Feature）投入训练，配合各种特征工程，可以提高模型的泛化能力。

而商品共购网络（Co-purchasing Network）是智能营销领域中的一种重要图数据，通过收集被用户一次性同时购买的商品信息，搭建商品之间的关联网络。而利用该网络，可以将商品按关联度聚类，构建商品列表，为各大网购平台中的“顺手买一件”、“看了又看”（Customers Who Buy This Item Also Buy）等功能提供策略支持，并在其他商品推荐、定价场景发挥作用，实现营销价值。

因此，利用 GCN 对商品共购网络进行分析，可以为智能营销领域提供新的思路和方法，为商品推荐、定价等场景提供更好的支持。

2 国内外研究现状

2.1 CGN 之前的工作

早在二十世纪末期，就有卷积神经网络（CNN）的概念，但当时的卷积神经网络仅将不同的滤波器（Filter）用于位图即规整的网格图，以采得不同尺度的特征，但要将卷积应用于一般图数据，其难点在于一般图特征在不同尺度上的提取。

而拉普拉斯矩阵（Laplace matrix）由图的邻接矩阵 A 导出，可以将其看作是一种图特征，表现了所有顶点的连通性，反映其该顶点位置为中心或离群。未归一化和已经归一化的拉普拉斯矩阵 L 表示如下，其中 D 为度数矩阵， A 为邻接矩阵：

$$D_{ii} = \sum_{j=1}^N A_{ij}, \quad L_{\text{unnormalized}} = D - A, \quad L_{\text{normalized}} = I_N - D^{-\frac{1}{2}} A D^{-\frac{1}{2}}.$$

2016 年的一篇论文 [7] 总结了在 GCN 之前的半监督图学习模型，强调归一化拉普拉斯矩阵对于半监督学习的重要性，半将 L 作为 Loss 的正则项以防止模型过平滑。这也为后续的 GCN 模型直接将拉普拉斯矩阵作为 Forwarding 函数提供了重要的参考。并且，该论文首先提出了 Citeseer 引用网络数据集，用于测试半监督图学习模型的分类能力。

2.2 CGN 模型提出

GCN 的研究始于 2017 年，由 Kipf 和 Welling 提出的 GCN 模型 [4]，是一种基于图的半监督学习方法，可用于 Citeseer 数据集。这篇论文使用拉普拉斯矩阵在本征空间上的不同缩放算子 g_θ 来实现不同尺度特征的提取。通过该卷积操作，将节点的特征信息传递给邻居节点，从而实现节点之间的信息传递。

$$g_\theta \star x = U g_\theta U^T x$$

上述式子必须进一步化简，否则大型图的 N 阶矩阵本征值分解将是无比耗时的。于是借助 2009 年 Hammond 等人提出的一种基于拉普拉斯矩阵的小波变换方法 [3]，这项研究利用了切比雪夫多项式 (Chebyshev polynomial) 在多项式 0-1 积分内积空间 $R^N[x]$ 上的正交性，得到了用多项式近似缩放算子的方法：

$$g_{\theta'}(\Lambda) \approx \sum_{k=0}^K \theta'_k T_k(\tilde{\Lambda}) \quad (1)$$

接着是进一步消去 Λ 和 U 。我们假设无向图，即邻接矩阵 A 是对称的；从而 L 也是对称的正规矩阵。由实谱定理 (Spectral theorem) 可知，在 R^N 实空间中存在由 L 的本征向量构成的标准正交基，这使得其本征值分解 $L = U^T \Lambda U$ 中， U 是酉矩阵 (等距同构)，满足 $U^T U = I_N$ 。从而有 $L^k = (U \Lambda U^T)^k = U \Lambda^k U^T$ 。这个等式说明，只需要使用关于 L 的多项式，即可表示 (1) 式。

$$g_{\theta'} \star x \approx \sum_{k=0}^K \theta'_k T_k(\tilde{L}) x$$

最后结合 renormalize trick 提升节点自身的 embedding feature 的重要性，便得出了 GCN 最基础的前向传播公式：

$$Z = \tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} X \Theta$$

2.3 局限与发展

但 GCN 并非万能，也存在如下局限性：

- GCN 由于直接将图的高维特征输入神经网络，并且在前向传播的过程中必须保存 $F_l \times N + F_{l+1} \times N$ 的嵌入特征数据，这使得 GCN 训练过程中消耗较大内存，对于比较大型的图数据，会导致训练效率低下。
- GCN 的原理推导使用了无向图的假设，因此不能直接应用于有向图。而对于有向图数据，需要额外的处理，例如增加一倍的冗余节点，将原图改造为无向的二分图，但这也会带来性能开支的增大。

之后，GCN 发展出了不同的变体，以应对一般图学习中层出不穷的场景。例如，引入注意力机制的图神经网络 GAT 便适用于有向图；使用采样和聚合的卷积网络算法 GraphSAGE，使其可扩展化，适用于更大规模的图数据。而在实际应用场景中，GCN 卷积层也搭配其他神经网络层，如池化层，LSTM、GRU，普通线性全链接层等，以实现深度学习，提高模型的泛化能力。

因此，在本次实验中，我们尝试在 GCN 基础模型的基础上添加更多实际应用中的技巧，以提高模型的性能。同时利用半监督数据的规模大小，探讨 GCN 在该模式下学习分类的极限训练数据大小。在后续章节的实验中，我们将详细介绍我们的实验设计和结果分析。

3 研究思路

我们遵循从原理到应用、从基础到扩展顺序展开研究：

1. 了解图神经网络原理，学习论文和 cs224w 课程中对于 GNN 的相关介绍，以及特征工程、网络搭建技巧，实现 Pytorch 版本的模型，并尽可能多地扩展可调参数。
2. 利用著名的 Citeseer 引用网络数据集，对比实验数据和论文数据，验证代码正确性。
3. 使用 Optuna 等超参数优化工具，对 GCN 模型的超参数进行调优，以提高模型的性能。
4. 借助正确的模型，对大型商品共购网络进行分析，探讨该模型在商品推荐领域的分类表现，与该模型处理大型数据集的能力。最终可视化商品共购网络，分析商品之间的关联性。
5. 有了以上模型和实验结果，我们将进一步探讨 GCN 在半监督学习中的极限训练数据大小，得到该模型学习能力的更直观认识。

首先，论文提供的是 tensorflow 版本的 GCN 模型 [4]，为了匹配现有环境，我们将其改写为 PyTorch 版本。

模型的可调节参数如下：

Column 1	Column 2	Column 3
Row 1, Cell 1	Row 1, Cell 2	Row 1, Cell 3
Row 2, Cell 1	Row 2, Cell 2	Row 2, Cell 3

表 1: Example table




图 1: Your caption text goes here

4 论文引用网络分析

5 亚马逊共购网络分析

亚马逊共购网络 and 商品分类真值 (Ground Truth) 数据集 [6] 将每个商品看成一个节点，这里的商品大部分是书籍、DVD 等物品。而节点之间的无向边表示两个商品曾经被一同购买，即“共同购买” (Co-purchasing) 关系。该数据集的情况大致如下：

节点总数	224863	无向边总数	925872
最大客群商品数量	214	最小客群商品数量	3
图的直径	44	特征维度	-

表 2: 亚马逊共购网络数据集情况

从中可以看出，这是一个大型的无向稀疏图，适用于 GCN 模型的训练。而我们的任务是根据共购关系，以及提供的少量商品分类真值数据，达到对全部商品的分类预测，从而为买过其中一种商品的推荐同类商品，并以此搭建商品客群。

但是，该数据的节点上并没有商品的特征信息，这使得 GCN 缺失了输入数据。为此，我们需要学习特征工程相关知识，计算商品的特征向量。

方法一是放弃使用任何特征向量增强训练，而只将 I_N 作为 X 输入模型。这个方法其实是利用图聚合卷积层本身的特征提取能力，在第一层完成特征的提取，而在第二层进行分类工作。在论文 [4] 中，作者也使用该方法成功提取了 Zachary's karate club network 数据集的节点特征。

方法二是使用无监督训练提取特征，例如 **RandomWalk**，该方法通过图上随机游走的方式，将节点的邻居节点信息融入到节点的特征向量中。其优点是简单易实现，现有的 **Node2vec** [1] 等工具正好适用于大型图的特征构建。但缺点是，该方法忽视了节点本身的特征（**Side information**）。以该例而言，商品的价格、种类、评价等信息均无法编码到特征上；而且，该方法在大型图中用时非常长，30 万节点，大致用了 14 分钟才编码为维数为 16 的特征。

方法三为实际中更常用的，基于元数据的商品特征提取。我们查询到商品 ID 背后的商品元数据信息 [5]。该数据集最初用于病毒营销检测，而我们只利用其商品的属性构建特征向量。

[2]

[7] [3] [8]

参考文献

- [1] Aditya Grover and Jure Leskovec. **node2vec: Scalable Feature Learning for Networks**, July 2016. *arXiv:1607.00653* [cs, stat] rate: 2.
- [2] William L. Hamilton, Rex Ying, and Jure Leskovec. **Inductive Representation Learning on Large Graphs**, September 2018. *arXiv:1706.02216* [cs, stat].
- [3] David K. Hammond, Pierre Vandergheynst, and Rémi Gribonval. **Wavelets on Graphs via Spectral Graph Theory**, December 2009.
- [4] Thomas N Kipf and Max Welling. **Semi-supervised classification with graph convolutional networks**. *arXiv preprint arXiv:1609.02907*, 2017.
- [5] Jure Leskovec, Lada A. Adamic, and Bernardo A. Huberman. **The dynamics of viral marketing**. *ACM Transactions on the Web*, 1(1):5, May 2007.
- [6] Jaewon Yang and Jure Leskovec. **Defining and Evaluating Network Communities based on Ground-truth**, May 2012.
- [7] Zhilin Yang, William W. Cohen, and Ruslan Salakhutdinov. **Revisiting Semi-Supervised Learning with Graph Embeddings**, May 2016. *arXiv:1603.08861* [cs] rate: 1.
- [8] Matthew D. Zeiler and Rob Fergus. **Visualizing and Understanding Convolutional Networks**, November 2013. *arXiv:1311.2901* [cs] rate: 1.